

曲線の推定3

山浦 剛 (tyamaura@riken.jp)

講義資料ページ


- http://climate.aics.riken.jp/members/yamaura/numerical_analysis.html

実験データからの推定

- 電流 I , 電圧 V , 抵抗 R の関係(オームの法則)
 - $V = RI$
- 電圧 V を色々変更して電流の値を調べる実験
 - 厳密には直線の上に実験値をプロットできるはず
 - 現実には誤差が含まれるため、そうはならない
- 測定結果から誤差をならした抵抗値(直線の傾き)を推定
 - この推定に使われる方法 ⇒ 最小2乗法

最小2乗法の原理

- N回の測定で得られた測定データ (x_i, y_i) ($i = 1, 2, \dots, N$) とする
- 理論式 $y = Ax$ が成立するとしたとき、残差平方和 $E(A) = \sum_{i=1}^N (y_i - Ax_i)^2$ を最小にするような係数 A を求める
 - $l_i = (y_i - Ax_i)$ の平方和
- 「各点から直線 $y = Ax$ に垂直に下した線分の長さの2乗の総和」が最も小さくなるような A の値を決める \Rightarrow 最小二乗法
- このときの A を \tilde{A} とする



最適な係数 $A = \tilde{A}$ の決定

- 次のような量を考える

- $\sum_{i=1}^N (y_i - Ax_i)^2 - \sum_{i=1}^N (y_i - \tilde{A}x_i)^2$

- この式中の A は任意の値として、この量の意味を考える。

- \tilde{A} は最小2乗法における最適な、すなわち誤差の平方和を最も小さくする係数 A を示す

- A は任意の値なので、誤差の平方和は \tilde{A} よりも必ず大きくなる

- A が \tilde{A} に等しいときのみ、この式はゼロとなる

- よって、この式は不等式に置き換えることができる

- $\sum_{i=1}^N (y_i - Ax_i)^2 - \sum_{i=1}^N (y_i - \tilde{A}x_i)^2 \geq 0$

最適な係数 $A = \tilde{A}$ の決定

➤ 式変形

- $\sum_{i=1}^N (y_i - Ax_i)^2 - \sum_{i=1}^N (y_i - \tilde{A}x_i)^2 \geq 0$
- $\sum_{i=1}^N (y_i^2 - 2Ax_iy_i + A^2x_i^2) - \sum_{i=1}^N (y_i^2 - 2\tilde{A}x_iy_i + \tilde{A}^2x_i^2) \geq 0$
- $\sum_{i=1}^N y_i^2 - 2A \sum_{i=1}^N x_iy_i + A^2 \sum_{i=1}^N x_i^2 - \sum_{i=1}^N y_i^2 + 2\tilde{A} \sum_{i=1}^N x_iy_i - \tilde{A}^2 \sum_{i=1}^N x_i^2 \geq 0$
- $-2A \sum_{i=1}^N x_iy_i + A^2 \sum_{i=1}^N x_i^2 + 2\tilde{A} \sum_{i=1}^N x_iy_i - \tilde{A}^2 \sum_{i=1}^N x_i^2 \geq 0$

➤ $p = \sum_{i=1}^N x_i^2, q = \sum_{i=1}^N x_iy_i$ と置き換える


- $-2Aq + A^2p + 2\tilde{A}q - \tilde{A}^2p \geq 0$
- $p \left(A^2 - 2A\frac{q}{p} - \tilde{A}^2 + 2\tilde{A}\frac{q}{p} \right) \geq 0$
- $p \left(A^2 - 2A\frac{q}{p} + \frac{q^2}{p^2} - \tilde{A}^2 + 2\tilde{A}\frac{q}{p} - \frac{q^2}{p^2} \right) \geq 0$
- $p \left\{ \left(A - \frac{q}{p} \right)^2 - \left(\tilde{A} - \frac{q}{p} \right)^2 \right\} \geq 0$

最適な係数 $A = \tilde{A}$ の決定

- $p > 0$ なので、式変形の結果、次の式を得る
 - $\left(A - \frac{q}{p}\right)^2 - \left(\tilde{A} - \frac{q}{p}\right)^2 \geq 0$
- A が任意の値を持つとき、この不等式を満たすには、 $\left(\tilde{A} - \frac{q}{p}\right)^2 = 0$ が成立する必要がある
 - $\tilde{A} = \frac{q}{p} = \frac{\sum_{i=1}^N x_i y_i}{\sum_{i=1}^N x_i^2}$
- 最適な係数 \tilde{A} は上の式で決定できる
 - オームの法則における抵抗係数 R は、実験値 I, V から上の式を用いて決定できる

最適な係数 $A = \tilde{A}$ の決定

- 最適な係数 \tilde{A} の決定に対する別解
 - $\sum_{i=1}^N (y_i - Ax_i)^2$ を最小にする A を探す \Rightarrow $\sum_{i=1}^N (y_i - Ax_i)^2$ の極小値を求める
- $\sum_{i=1}^N (y_i - Ax_i)^2$ の微分係数をゼロとする A を求める
 - $\frac{d}{dA} \sum_{i=1}^N (y_i - Ax_i)^2 = 0$
 - $\frac{d}{dA} \sum_{i=1}^N (y_i^2 - 2Ax_iy_i + A^2x_i^2) = 0$
 - $\sum_{i=1}^N (-2x_iy_i + 2Ax_i^2) = 0$
 - $2\{A \sum_{i=1}^N x_i^2 - \sum_{i=1}^N x_iy_i\} = 0$
 - $2\{Ap - q\} = 0$



2つの未知定数を含む最小2乗法

- N回の測定で得られた測定データ (x_i, y_i) ($i = 1, 2, \dots, N$)に対し、理論式 $y = Ax + B$ が成立する場合を考える
- 未知定数が1つの場合と同様、「各点から直線 $y = Ax + B$ に垂直に下した線分の長さの2乗の総和」が最も小さくなるような A, B の値を決める
- 残差平方和を最小にするような係数 A, B を求める
 - $E(A, B) = \sum_{i=1}^N (y_i - Ax_i - B)^2$
- 各係数の最適値 \tilde{A}, \tilde{B} を求める
 - 微分係数がゼロとなる A, B を求めればよい

2つの未知定数を含む最小2乗法

➤ $E(A, B)$ に対し、 A の偏微分を行う

➤
$$\frac{\partial E}{\partial A} = \frac{\partial}{\partial A} \sum_{i=1}^N (y_i - Ax_i - B)^2$$

➤
$$\frac{\partial E}{\partial A} = \frac{\partial}{\partial A} \sum_{i=1}^N (A^2 x_i^2 - 2Ax_i y_i + 2ABx_i + y_i^2 + B^2 - 2By_i)$$

➤
$$\frac{\partial E}{\partial A} = \sum_{i=1}^N (2Ax_i^2 - 2x_i y_i + 2Bx_i)$$

➤
$$\frac{\partial E}{\partial A} = 2\{A \sum_{i=1}^N x_i^2 + B \sum_{i=1}^N x_i - \sum_{i=1}^N x_i y_i\} = 0$$

➤ $E(A, B)$ に対し、 B の偏微分を行う

➤
$$\frac{\partial E}{\partial B} = \frac{\partial}{\partial B} \sum_{i=1}^N (A^2 x_i^2 - 2Ax_i y_i + 2ABx_i + y_i^2 + B^2 - 2By_i)$$

➤
$$\frac{\partial E}{\partial B} = \sum_{i=1}^N (2Ax_i + 2B - 2y_i)$$

➤
$$\frac{\partial E}{\partial B} = 2\{A \sum_{i=1}^N x_i + BN - \sum_{i=1}^N y_i\} = 0$$

2つの未知定数を含む最小2乗法

- 即ち2つの未知定数に対して、2つの条件を満たさなければならない(正規方程式)

- $$\begin{cases} \frac{\partial E}{\partial A} = 2\{A \sum_{i=1}^N x_i^2 + B \sum_{i=1}^N x_i - \sum_{i=1}^N x_i y_i\} = 0 \\ \frac{\partial E}{\partial B} = 2\{A \sum_{i=1}^N x_i + BN - \sum_{i=1}^N y_i\} = 0 \end{cases}$$

- これは未知定数 A, B の連立一次方程式となっている

- $p = \sum_{i=1}^N x_i^2, q = \sum_{i=1}^N x_i y_i, r = \sum_{i=1}^N x_i, s = \sum_{i=1}^N y_i$ とおく

- $$\begin{cases} 2\{Ap + Br - q\} = 0 \\ 2\{Ar + BN - s\} = 0 \end{cases}$$

- 連立方程式の2番目の式より、

- $$B = \frac{s - Ar}{N}$$

- 連立方程式の1番目の式に代入し、

- $$Ap + \frac{s - Ar}{N}r - q = 0$$

- $$ANp + rs - Ar^2 - Nq = 0$$

- $$A(Np - r^2) = Nq - rs$$

- $$A = \frac{Nq - rs}{Np - r^2}$$

2つの未知定数を含む最小2乗法

- 未知定数 (A, B) を p, q, r, s で表現

$$\begin{aligned} \text{➤ } \begin{cases} A = \frac{Nq-rs}{Np-r^2} \\ B = \frac{s-r\frac{Nq-rs}{Np-r^2}}{N} \end{cases} &\Rightarrow \begin{cases} A = \frac{Nq-rs}{Np-r^2} \\ B = \frac{1}{N} \left\{ \frac{(Nps-r^2s)-Nqr+r^2s}{Np-r^2} \right\} \end{cases} \Rightarrow \begin{cases} A = \frac{Nq-rs}{Np-r^2} \\ B = \frac{ps-qr}{Np-r^2} \end{cases} \end{aligned}$$

- このときの未知定数 $(A, B) = (\tilde{A}, \tilde{B})$ であるので、

$$\begin{aligned} \text{➤ } \begin{cases} \tilde{A} = \frac{N \sum_{i=1}^N x_i y_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{N \sum_{i=1}^N x_i^2 - (\sum_{i=1}^N x_i)^2} \\ \tilde{B} = \frac{\sum_{i=1}^N x_i^2 \sum_{i=1}^N y_i - \sum_{i=1}^N x_i y_i \sum_{i=1}^N x_i}{N \sum_{i=1}^N x_i^2 - (\sum_{i=1}^N x_i)^2} \end{cases} \end{aligned}$$

2つの未知定数を含む最小2乗法

➤ 実際のデータが与えられたとき、この形で定数(\tilde{A}, \tilde{B})を計算するのは厄介

➤ 統計情報を使って、計算方法の変換を行ってやる

➤
$$B = \frac{s - Ar}{N} = \frac{s}{N} - \frac{r}{N}A$$

➤ ここで標本平均 \bar{X}, \bar{Y} を用い、 $\bar{X} = \frac{r}{N} = \frac{1}{N} \sum_{i=1}^N x_i$, $\bar{Y} = \frac{s}{N} = \frac{1}{N} \sum_{i=1}^N y_i$ として置き換える

➤
$$B = \bar{Y} - \bar{X}A$$

➤ 同様に、標本平均で定数 A を書き換える

➤
$$A = \frac{Nq - rs}{Np - r^2} = \frac{\frac{q}{N} - \frac{rs}{N^2}}{\frac{p}{N} - \left(\frac{r}{N}\right)^2} = \frac{\frac{q}{N} - \bar{X}\bar{Y}}{\frac{p}{N} - \bar{X}^2} = \frac{\sum_{i=1}^N x_i y_i - N\bar{X}\bar{Y}}{\sum_{i=1}^N x_i^2 - N\bar{X}^2}$$


➤
$$A = \frac{\sum_{i=1}^N x_i y_i - 2N\bar{X}\bar{Y} + N\bar{X}\bar{Y}}{\sum_{i=1}^N x_i^2 - 2N\bar{X}^2 + N\bar{X}^2} = \frac{\sum_{i=1}^N x_i y_i - \bar{Y} \sum_{i=1}^N x_i - \bar{X} \sum_{i=1}^N y_i + \sum_{i=1}^N \bar{X}\bar{Y}}{\sum_{i=1}^N x_i^2 - 2\bar{X} \sum_{i=1}^N x_i + \sum_{i=1}^N \bar{X}^2} = \frac{\sum_{i=1}^N (x_i y_i - x_i \bar{Y} - y_i \bar{X} + \bar{X}\bar{Y})}{\sum_{i=1}^N (x_i^2 - 2x_i \bar{X} + \bar{X}^2)} = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^N (x_i - \bar{X})^2}$$

2つの未知定数を含む最小2乗法

- 即ち、定数 (\tilde{A}, \tilde{B}) は次のように求めることもできる
 - $\tilde{A} = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^N (x_i - \bar{X})^2} = \frac{V_{xy}}{V_x}$
 - $\tilde{B} = \bar{Y} - \bar{X}\tilde{A}$
 - ここで V_{xy} は x と y の共分散、 V_x は x の分散を示す
- 統計学における分散 V , 標準偏差 S , 相関係数 r を使えば
 - $\tilde{A} = \frac{V_{xy}}{V_x} = \frac{V_{xy}}{S_x S_y} \frac{S_y}{S_x} = r_{xy} \frac{S_y}{S_x}$
- という変形を行うこともできる

2乗による距離推定の妥当性

- 距離推定を最小「2乗」で行うのはなぜか？
 - 正と負の誤差で、お互いに打ち消しあわないようにするため
 - ならば絶対値で求めてもよい ⇒ 最小絶対値法
- しかし、最小絶対値法は一般的ではない
 - 点(0, 0) (0, 1) (2, 1) (2, 2)の4点のデータが与えられたときの尤もらしい直線を考える
 - 最小二乗法 ⇒ $y = \frac{1}{2}x + \frac{1}{2}$ という回帰式を得る
 - 誤差推定: 2乗距離ならば1, 絶対距離ならば2となる
 - $y = 2x$ という直線を考える
 - 誤差推定: 2乗距離ならば2, 絶対距離ならば2となる
 - 最小絶対値法では、一意に係数が決まらない
 - 4乗、6乗も同様に、一意に決まらない可能性がある



線形最小2乗法

- 理論式の複雑、かつ未知定数が多くても、最小2乗法を適用することはできる
- N 回の測定で得られた測定データ (x_i, y_i) ($i = 1, 2, \dots, N$) に対し、 M 個の未知定数 A_i ($i = 1, 2, \dots, M$) を含む理論式を考える
 - $y = \sum_{i=1}^M A_i f_i(x)$
- ここで、 $f_i(x)$ は予め与えられており、互いに1次独立な x の関数とする
 - $M = 2, A_1 = A, A_2 = B, f_1(x) = x, f_2(x) = 1$ とすると、 $y = Ax + B$ の理論式に等しい
- 最適な A_i の組み合わせは、次の誤差関数 E を最小にするものである
 - $E(A_1, A_2, \dots, A_M) = \sum_{j=1}^N (y_j - \sum_{i=1}^M A_i f_i(x_j))^2$

線形最小2乗法

- したがって、下記の式を全て満足する A_i の組を探せばよい

- $\frac{\partial E}{\partial A_k} = -2 \sum_{j=1}^N \{f_k(x_j)(y_j - \sum_{i=1}^M A_i f_i(x_j))\} = 0 \quad (k = 1, 2, \dots, M)$

- 最適値 \widetilde{A}_i を求める式は、次のように導かれる

- $\sum_{j=1}^N \{f_k(x_j)(y_j - \sum_{i=1}^M \widetilde{A}_i f_i(x_j))\} = 0$

- $\sum_{j=1}^N \{y_j f_k(x_j) - f_k(x_j) \sum_{i=1}^M \widetilde{A}_i f_i(x_j)\} = 0$

- $\sum_{j=1}^N \{y_j f_k(x_j)\} = \sum_{j=1}^N \{f_k(x_j) \sum_{i=1}^M \widetilde{A}_i f_i(x_j)\}$

- $\sum_{j=1}^N y_j f_k(x_j) = \sum_{j=1}^N \sum_{i=1}^M \widetilde{A}_i f_k(x_j) f_i(x_j)$

- $\sum_{j=1}^N y_j f_k(x_j) = \sum_{i=1}^M \widetilde{A}_i \{\sum_{j=1}^N f_k(x_j) f_i(x_j)\} \quad (k = 1, 2, \dots, M)$

線形最小2乗法

- ここで、 $p_{k,i}$ と q_k を次のように定義する

- $p_{k,i} = \sum_{j=1}^N f_k(x_j) f_i(x_j)$

- $q_k = \sum_{j=1}^N y_j f_k(x_j)$

- よって最適値 \widetilde{A}_i の式は、次のように変形できる

- $q_k = \sum_{i=1}^M \widetilde{A}_i p_{k,i} \quad (k = 1, 2, \dots, M)$

- \widetilde{A}_i に関する連立方程式なので、行列で表記できる

- $$\begin{bmatrix} p_{1,1} & p_{1,2} & \cdots & p_{1,M} \\ p_{2,1} & p_{2,2} & \cdots & p_{2,M} \\ \vdots & \vdots & \ddots & \vdots \\ p_{M,1} & p_{M,2} & \cdots & p_{M,M} \end{bmatrix} \begin{bmatrix} \widetilde{A}_1 \\ \widetilde{A}_2 \\ \vdots \\ \widetilde{A}_M \end{bmatrix} = \begin{bmatrix} q_1 \\ q_2 \\ \vdots \\ q_M \end{bmatrix}$$

- 方程式の性質から特別な解法が考えられている(例えばQR分解)
- 単純な方程式の場合、ガウスの消去法などのシンプルな解法で解くこともできる